Lead Scoring Prédictif

Voici un guide méthodologique complet et opérationnel pour concevoir, implémenter et soutenir ce projet de **Lead Scoring Prédictif** dans le cadre du module **Web Marketing & CRM**, en mobilisant les leviers de l'intelligence artificielle et de la transformation digitale.

1. Démarche d'Implémentation :

La démarche pour réaliser ce prototype fonctionnel s'articule autour des étapes suivantes :

⇒ **Acquisition des Données :** Il faut générer ou utiliser un jeu de données de leads contenant des variables marketing telles que: ***la source***, ***le secteur***, ***les pages vues*** et ***les e-mails ouverts***;

⇒ **Modélisation IA :** L'objectif est d'entraîner un modèle de machine learning capable de ***prédire la probabilité de conversion d'un lead***. Cette approche prédictive basée sur l'intelligence artificielle doit ensuite être ***comparée au scoring manuel traditionnel***;

⇒ **Intégration CRM :** Une fois les scores calculés, ils doivent être ***intégrés dans Odoo en utilisant un fichier d'import*** pour mettre à jour le champ de probabilité ou la priorité des opportunités.

2. Choix et Justification du Second CRM à coté d'Odoo CRM (avec des limites 2026):

✓ **HubSpot CRM:** En 2026, l'offre gratuite en ligne est plafonnée à 2 utilisateurs et 1 000 contacts. Elle inclut la marque HubSpot sur les e-mails et le chat, et limite l'analyse à 10 tableaux de bord. Toutefois, son orientation native vers l'inbound marketing (tracking de l'engagement) le rend idéal pour capturer et illustrer les variables comportementales (pages vues, e-mails ouverts) nécessaires à l'entraînement du modèle d'IA. Le plafond de 1 000 contacts est par ailleurs largement suffisant pour importer un jeu de données test et réaliser un prototype fonctionnel.

3. Livrables Attendus pour la Démonstration:

- **Notebook :** Le code informatique (généralement Python) détaillant ***l'exploration des données et l'entraînement du modèle***;
- **Courbe ROC :** Une visualisation graphique de ***la performance du modèle***;
- **Fichier d'import :** Le document structure (est le format **CSV** ou, à défaut, le format **Excel (.xlsx)**) contenant les leads et leurs scores prédictifs calculés;
- **Démonstration :** Une présentation en direct dans Odoo montrant le pipeline de ventes trié par le score.

4. Jeu de Données - Source et Variables Marketing:

Pour rendre le prototype réaliste, on peut exploiter un jeu de données public standard du domaine : le dataset Kaggle **« Lead Scoring Dataset »** (issu d'une plateforme d'e-learning / EdTech. Il comprend 9 240 leads et 37 attributs.

Le lien à Dataset (Kaggle): https://www.kaggle.com/datasets/amritachatterjee09/lead-scoring-dataset.

Variables recommandées pour entraîner le modèle (Features web marketing):

- Variable cible (Target) : 'Converted' (0 = lead perdu, 1 = lead converti).
- Canaux d'acquisition : 'Lead Origin' (origine de la piste : Landing Page Submission, API, Lead Add Form) et 'Lead Source' (Google, Direct Traffic, Organic Search, Referral Sites, etc.).
- Métriques comportementales web : 'TotalVisits' (nombre de visites), 'Total Time Spent on Website' (temps total passé sur le site en secondes) et 'Page Views Per Visit' (pages vues par session).
- Engagement et nurturing : 'Last Activity' (dernière interaction : Email Opened, SMS Sent, Page Visited) et 'Do Not Email' (opt-out emailing).
- Profil et secteur : 'Specialization' (secteur professionnel ou domaine d'études) et 'What is your current occupation' (statut : salarié, demandeur d'emploi, étudiant).

5. Implémentation dans le Notebook Jupyter / Colab:

Le notebook se structure en 4 blocs obligatoires:

- **Étape A : Prétraitement et Nettoyage**

```
import numpy as np
import pandas as pd

# ------------------------------------------------------------------------
# ÉTAPE 1 : Chargement et conversion des faux "Select" en NaN
# ------------------------------------------------------------------------
df = pd.read_csv("Lead Scoring.csv")

df = df.replace("Select", np.nan)

# ------------------------------------------------------------------------
# ÉTAPE 2 : Suppression des identifiants et des colonnes "Data Leakage"
# ------------------------------------------------------------------------
ids_to_drop = ["Prospect ID", "Lead Number"]

# 2. Variables remplies par les équipes commerciales APRÈS contact (Data Leakage)
sales_leakage_cols = [
    "Tags",
    "Lead Quality",
    "Lead Profile",
    "Asymmetrique Activity Index",
    "Asymmetrique Profile Index",
```

```
    "Asymmetrique Activity Score",
    "Asymmetrique Profile Score",
    "Last Notable Activity",  # Redondant avec 'Last Activity' et souvent mis à jour
manuellement
]

df.drop(columns=ids_to_drop + sales_leakage_cols, inplace=True, errors="ignore")

# ------------------------------------------------------------------------
# ÉTAPE 3 : Suppression des colonnes trop creuses (> 40% de valeurs manquantes)
# ------------------------------------------------------------------------
# Calcul du pourcentage de valeurs manquantes
missing_percentage = (df.isnull().sum() / len(df)) * 100
cols_high_missing = missing_percentage[missing_percentage > 40].index.tolist()

# Note : On conserve 'Specialization' si elle est dans la liste, car un lead qui
# ne précise pas son secteur est une information métier pertinente (Non renseigné)
if "Specialization" in cols_high_missing:
  cols_high_missing.remove("Specialization")

df.drop(columns=cols_high_missing, inplace=True)

# ------------------------------------------------------------------------
# ÉTAPE 4 : Suppression des colonnes constantes ou univariées
# ------------------------------------------------------------------------
skewed_cols = [
    col
    for col in df.columns
    if df[col].value_counts(normalize=True, dropna=False).values[0] > 0.98
    and col != "Converted"
]
df.drop(columns=skewed_cols, inplace=True)

# ------------------------------------------------------------------------
# ÉTAPE 5 : Standardisation et regroupement des modalités (Web Marketing)
# ------------------------------------------------------------------------
# A. Nettoyage de 'Lead Source'
if "Lead Source" in df.columns:
  # Harmonisation de la casse
  df["Lead Source"] = df["Lead Source"].replace({"google": "Google"})

  # Regroupement des sources à très faible volume sous 'Other_Source'
  top_sources = [
      "Google",
      "Direct Traffic",
      "Organic Search",
      "Olark Chat",
      "Reference",
  ]
  df["Lead Source"] = df["Lead Source"].apply(
      lambda x: x if x in top_sources else ("Other_Source" if pd.notnull(x) else x)
  )
  df["Lead Source"].fillna("Other_Source", inplace=True)
```

```python
# B. Traitement des variables de profil (Spécialisation et Métier)
if "Specialization" in df.columns:
  df["Specialization"].fillna("Not_Specified", inplace=True)

if "What is your current occupation" in df.columns:
  df["What is your current occupation"].fillna("Unemployed", inplace=True)

if "Last Activity" in df.columns:
  top_activities = [
      "Email Opened",
      "SMS Sent",
      "Page Visited on Website",
      "Olark Chat Conversation",
  ]
  df["Last Activity"] = df["Last Activity"].apply(
      lambda x: (
          x if x in top_activities else ("Other_Activity" if pd.notnull(x) else x)
      )
  )
  df["Last Activity"].fillna("Other_Activity", inplace=True)

# ---------------------------------------------------------------------------
# ÉTAPE 6 : Traitement des variables numériques & Outliers (Écrêtage)
# ---------------------------------------------------------------------------
num_cols = ["TotalVisits", "Total Time Spent on Website", "Page Views Per Visit"]
num_cols = [c for c in num_cols if c in df.columns]

# Imputation par la médiane pour les variables web
for col in num_cols:
  median_val = df[col].median()
  df[col].fillna(median_val, inplace=True)

# Plafonnement des valeurs extrêmes (Outliers) au 99ème percentile
# (Ex : un robot qui visite 200 pages en une session fausserait les coefficients)
for col in ["TotalVisits", "Page Views Per Visit"]:
  if col in df.columns:
    q_99 = df[col].quantile(0.99)
    df[col] = np.where(df[col] > q_99, q_99, df[col])

# ---------------------------------------------------------------------------
# ÉTAPE 7 : Encodage des variables binaires (Yes / No)
# ---------------------------------------------------------------------------
binary_cols = ["Do Not Email", "Do Not Call"]
for col in binary_cols:
  if col in df.columns:
    df[col] = df[col].map({"Yes": 1, "No": 0}).fillna(0).astype(int)

# ---------------------------------------------------------------------------
# DIAGNOSTIC FINAL APRÈS NETTOYAGE
# ---------------------------------------------------------------------------
print(f"Dimensions du dataset final prêt à modéliser : {df.shape}")
print(
    f"Nombre de valeurs manquantes restantes : {df.isnull().sum().sum()} (doit être 0)"
)
```

```
print("\nDistribution de la variable cible 'Converted' :")
print(df["Converted"].value_counts(normalize=True).round(3))
```

- **Étape 2 : Modélisation du Scoring Manuel (Benchmark Métier)**

Le sujet exige de **comparer le modèle IA au scoring manuel**. On crée une fonction qui simule la grille de points arbitraire qu'un responsable marketing utilise habituellement :

```
def manual_lead_score(row):
  score = 0
  # Règles arbitraires basées sur l'intuition marketing classique
  if row.get("Lead Source") in ["Google", "Reference"]:
    score += 25
  if row.get("Total Time Spent on Website", 0) > 400:
    score += 35
  elif row.get("Total Time Spent on Website", 0) > 150:
    score += 15
  if row.get("Last Activity") in ["Email Opened", "SMS Sent"]:
    score += 25
  if row.get("TotalVisits", 0) >= 3:
    score += 15

  # Normalisation entre 0 et 1 (probabilité équivalente)
  return min(score, 100) / 100.0


# Calcul du score manuel sur le jeu de test
y_scores_manual = X_test.apply(manual_lead_score, axis=1)
```

- **Étape 3 : Entraînement du Modèle IA Prédictif**

- **Étape 4 : Évaluation comparative et Courbe ROC (Livrable attendu)**

6. Préparation et Génération des Fichiers d'Import CRM pour Odoo & HubSpot (Livrable attendu):

7. Démonstration Pratique pas-à-pas dans les CRM (Odoo & HubSpot) (Livrable attendu):